

# Implementacija vmesnika možgani računalnik za klasifikacijo med dvema motoričnima aktivnostima

Anja Brelih

Univerza v Ljubljani, Fakulteta za računalništvo in informatiko  
Večna pot 113, 1000 Ljubljana

Januar 2023  
ab0555@student.uni-lj.si

## 1 Uvod

Pri interakciji med računalnikom in možgani se ukvarjamo z možganskimi signali, ki opisujejo aktivnosti v različnih delih možganov. Možgansko aktivnost je mogoče zaslediti že, ko pomislemo na neko fizično aktivnost. V kolikor znamo ta signal pravilno zajeti in ga obdelati, lahko na podlagi tega ustvarjamo interakcijo med možgani in računalnikom. Take podatke lahko zajamemo z elektroencefalografijo (EEG) – tehniko iz nevroznanosti, ki meri električno aktivnost možganske skorje možganov [1].

V kolikor imamo podatke o motoričnih aktivnostih (dejanskih ali zamišljenih), lahko EEG signale uporabimo za klasifikacijo med dvema motoričnima aktivnostima. Pred generacijo klasifikacijskih značilk je potrebno signale filtrirati s prostorskim in nato še spektralnim filtrom, da iz podatkov izločimo čim več šuma.

## 2 Metode

Izbrani signal smo s pomočjo anotacij aktivnosti, ki jih je testni subjekt izvajal med zajemanjem signala, razdelili na intervale, ki ločujejo dve različni aktivnosti za kateri gradimo naš klasifikator.

Za prostorski filter smo uporabili metodo skupnih prostorskih vzorcev SPV (ang. Common Spatial Patterns CSP), ki najde transformacijo, ki maksimizira varianco signalov enega stanja in simultano minimizira varianco signalov drugega stanja. Koeficienti v dobljeni matriki  $W$  maksimizirajo razmerje v variancah dveh različnih stanj (dve različni nalogi) oziroma dveh različnih razredih [2]. Za učenje prostorskih vzorcev in izgradnje matrike  $W$  uporabimo prvi interval obeh stanj ter jih nato odstranimo iz celice, kjer se nahajajo vsi intervali. Z množenjem intervalov posamezne aktivnosti  $sigT_i$  z matriko  $W$ , dobimo  $CSP\_sigT_i$  prostorsko filtriran signal intervala aktivnosti (1)

$$CSP\_sigT_i = W * sigT_i. \quad (1)$$

Dobljene signale v prostoru komponent nato filtriramo še s spektralnim pasovno prepustnim filtrom s končnim enotnim odzivom KEO (ang. Finite impulse response FIR). KEO filtri so vedno stabilni, saj so nereurzivni in ni povratne vezave [3]. Filter smo implementirali z uporabo Matlab funkcije *firls*, ki predstavlja KEO filter z linearno fazo najmanjših

kvadratov na podlagi vhodnih parametrov (število točk  $n$ , frekvence prepuščanja deljene z Nyquistovo frekvenco  $f$  ter intervale prepuščanja in dušenja filtra *ints*) vrne vektor vrstice  $b$ , ki vsebuje  $n+1$  koeficientov KEO filtra reda  $n$ . Frekvenčne in amplitudne značilnosti dobljenega filtra se ujemata s tistimi, ki jih podajata vektorja  $f$  in *ints* (2) [4]

$$b(k) = b(n + 2 - k), k = 1, \dots, n + 1. \quad (2)$$

Izbrane frekvence prepuščanja, ki smo jih uporabili pri grajenju filtra so od 8 Hz do 13 Hz. Število točk  $n$  oziroma red KEO filtra smo spreminjali tekom testiranja z namenom pridobitve boljših končnih rezultatov.

Za generacijo značilk v prostoru komponent smo za prostorsko in spektralno filtrirane signale intervalov aktivnosti izračunali logaritem variance. Značilke dobljene v frekvenčnem prostoru smo pridobili preko močnostnih spektrov dobljenih signalov.

Dobljene značilke smo nato uporabili za klasifikacijo med dvema različnima aktivnostima z linerno diskriminantno analizo LDA (ang. Linear Discriminant Analysis) ter kvadratično diskriminantno analizo KDA (ang. Quadratic Discriminant Analysis QDA). LDA privzame, da so razredi linearno ločljivi in tako definira linearno diskriminantno funkcijo, ki predstavlja hiperravnino v prostoru značilk za ločevanje razredov [5]. KDA je različica LDA, v kateri je posamezna kovariančna matrika ocenjena za vsak razred opazovanj. Pomankljivost KDA je, da je ni mogoče uporabiti kot tehniko zmanjševanja dimenzij. Z uporabo KDA je mogoče modelirati nelinearne odnose [6].

## 3 Rezultati

Programsko kodo smo implementirali v okolju Matlab ter uporabili podatke iz podatkovne baze EEGMMI DS. Podatkovna baza zajema preko 1500 eno in dvo minutnih EEG zajemov podatkov, ki so bili izvedeni na 109 testnih subjektih. Ti so opravljali različne motorične sli slikovne naloge, medtem ko je bil 64-kanalni EEG posnet s sistemom BCI2000. Vsak testni subjekt je izvedel 14 poskusnih tekov: dva enominutna izhodiščna teka (prvega z odprtimi očmi ter drugega z zaprtimi očmi) ter tri dvominutne teke vsake od štirih testnih nalog:

1. Ob prikazu tarče na zaslonu subjekt odpira in zapira pest leve ali desne roke.


2. Ob prikazu tarče na zaslonu si subjekt predstavlja odpiranje in zapiranje pesti leve ali desne roke.
3. Ob prikazu tarče na vrhu zaslona subjekt odpira in zapira obe pesti ter ob prikazu tarče na dnu zaslona subjekt stiska stopala.
4. Ob prikazu tarče na vrhu zaslona si subjekt predstavlja odpiranje in zapiranje obeh pesti ter ob prikazu tarče na dnu zaslona si subjekt predstavlja stiskanje stopal.

Podatki vsebujejo anotacije (T0, T1, T2), ki predstavljajo aktivnosti, ki jih je testni subjekt izvajal. T0 označuje mirovanje, T1 označuje aktivnost (resnično ali namišljeno) leve pesti ali obeh pesti ter T2 označuje aktivnost (resnično ali namišljeno) desne pesti ali obeh stopal [7].


Ob zagonu programske kode implementirane v programskem jeziku Matlab, uporabnik najprej definira enega iz izmed 109 testnih subjektov v uporabljene podatkovni baze ter izbere željeno motorično aktivnost na kateri se izvede klasifikacija. Motorične aktivnosti so razdeljene v štiri sklope: a.) zapiranje in odpiranje desne ali leve dlani, b.) zamišljanje zapiranja in odpiranja desne ali leve dlani, c.) zapiranje in odpiranje obeh dlani ali stopal in d.) zamišljanje zapiranja in odpiranja obeh dlani ali stopal. Vsak sklop vsebuje 3 poskusne teke opravljanja enakih motoričnih aktivnosti.

Implementirano klasifikacijo med dvema motoričnima aktivnostima bomo predstavili na testnem subjektu 12 z motoričnimi aktivnostmi zapiranja in odpiranja desne ali leve dlani. Za določanje uspešnosti klasifikacije smo uporabili senzitivnost (SE), specifičnost (SP), klasifikacijsko točnost (CA) ter površino pod krivuljo ROC (ang. Area Under the ROC Curve AUC).

Pri testiranju uspešnosti delovanja smo spreminjali parameter števila točk  $n$  oziroma red KEO filtra z namenom pridobivanja boljših rezultatov. V začetku smo za parameter  $n$  uporabili vrednost 35 ter pridobili značilke aktivnosti v prostoru komponent (Slika 1) ter v frekvenčnem prostoru preko močnostnih spektrov (Slika 2). Na podlagi značilk smo z LDA in KDA klasificirali motorične aktivnosti (Tabela 1).



Slika 1: Značilke aktivnosti T1 in T2 v prostoru komponent z uporabo KEO filtra pri  $n = 35$



Slika 2: Značilke aktivnosti T1 in T2 v frekvenčnem prostoru preko močnostnih spektrov z uporabo KEO filtra pri  $n = 35$


Tabela 1: Rezultat klasifikacije LDA in KDA z uporabo KEO filtra pri  $n = 35$

	SE	SP	CA	AUC
<b>LDA</b>	69.57	35.00	53.49	61.30
<b>KDA</b>	78.26	50.00	65.12	74.35


Vrednost števila točk  $n$  KEO filtra smo večkrat spremenili, najboljši rezultat smo za iste vhodne podatke dosegli pri vrednosti 69. Pridobili smo značilke aktivnosti v prostoru komponent (Slika 3) ter v frekvenčnem prostoru preko močnostnih spektrov (Slika 4). Na podlagi teh značilk smo z LDA in KDA klasificirali motorične aktivnosti ter pridobili boljše rezultate klasifikacijske točnosti (Tabela 2).

Tabela 2: Rezultat klasifikacije LDA in KDA z uporabo KEO filtra pri  $n = 69$

	SE	SP	CA	AUC
<b>LDA</b>	78.26	75.00	76.74	76.96
<b>KDA</b>	78.26	70.00	74.42	79.57



Slika 3: Značilke aktivnosti T1 in T2 v prostoru komponent z uporabo KEO filtra pri  $n = 69$



Slika 4: Značilke aktivnosti T1 in T2 v frekvenčnem prostoru preko močnostnih spektrov z uporabo KEO filtra pri  $n = 69$

## 4 Diskusija

S pridobljenimi rezultati smo v splošnem zadovoljni, čeprav verjamemo, da bi bili z boljšim filtriranjem lahko še boljši.

Za pridobitev končne ocene uspešnosti bi morali implementirano filtriranje ter klasifikacijo poskusiti še na drugih testnih subjektih ter drugih motoričnih aktivnostih. V nadaljevanju bi lahko poskušali rezultate izboljšati tudi z določanjem drugih pragov pasovne prepustnosti pri uporabi KEO filtra (npr. od 8 Hz do 30 Hz). Smiselno bi bilo testirati tudi delovanje Parks-McClellan KEO filtra.

Na uspeh klasifikacije nedvomno vpliva tudi število značilk, ki jih je v primeru testnega subjekta 12 za motorične aktivnosti 3, 7 in 11 le 20 za aktivnost T2 in 23 za aktivnost T1. Za pridobitev boljših rezultatov klasifikacije bi bilo potrebno uporabiti še več testnih poskusov iste aktivnosti pri istem subjektu ter tako pridobiti več značilk za posamezen razred.

Cilj za nadaljno delo je pridobiti značilke, ki s klasifikatorjema LDA in KDA prineseta klasifikacijsko točnost nad 80% ali celo 85%.

## Literatura

- [1] F. Jager, "Komunikacija človek računalnik: Elektroencefalogram (EEG) in vmesnik možgani računalnik," 2022 [Elektronski]. Dostopen: [https://ucilnica.fri.uni-lj.si/pluginfile.php/100073/mod\\_resource/content/29/6.Elektroencefalogram\\_in\\_komunikacija\\_mozgan\\_i\\_racunalknik\\_xxx.pdf](https://ucilnica.fri.uni-lj.si/pluginfile.php/100073/mod_resource/content/29/6.Elektroencefalogram_in_komunikacija_mozgan_i_racunalknik_xxx.pdf). [Poskus dostopa januar 2023].
- [2] F. Jager, "Komunikacija človek računalnik: Predobdelava in izločanje časovnih ter prostorskih značilk, I," 2022 [Elektronski]. Dostopen: [https://ucilnica.fri.uni-lj.si/pluginfile.php/100241/mod\\_resource/content/48/8.Predobdelava\\_in\\_izlocanje\\_casovnih\\_ter\\_prostorskih\\_znacilk\\_I\\_xxx.pdf](https://ucilnica.fri.uni-lj.si/pluginfile.php/100241/mod_resource/content/48/8.Predobdelava_in_izlocanje_casovnih_ter_prostorskih_znacilk_I_xxx.pdf). [Poskus dostopa januar 2023].
- [3] F. Jager, "Komunikacija človek računalnik: Predobdelava in izločanje časovnih ter prostorskih značilk, II," 2022 [Elektronski]. Dostopen: [https://ucilnica.fri.uni-lj.si/pluginfile.php/132806/mod\\_resource/content/46/8.Predobdelava\\_in\\_izlocanje\\_casovnih\\_ter\\_prostorskih\\_znacilk\\_II\\_new\\_xxx.pdf](https://ucilnica.fri.uni-lj.si/pluginfile.php/132806/mod_resource/content/46/8.Predobdelava_in_izlocanje_casovnih_ter_prostorskih_znacilk_II_new_xxx.pdf). [Poskus dostopa januar 2023].
- [4] MathWorks, "firls," 2023 [Elektronski]. Dostopen: <https://www.mathworks.com/help/signal/ref/firls.html>. [Poskus dostopa januar 2023].
- [5] F. Jager, "Komunikacija človek računalnik: Klasifikacije in VMR s strojnimi učenjem," 2022 [Elektronski]. Dostopen: [https://ucilnica.fri.uni-lj.si/pluginfile.php/100935/mod\\_resource/content/52/10.Klasifikacije\\_in\\_VMR\\_s\\_strojnimi\\_ucenjem\\_1920\\_new.pdf](https://ucilnica.fri.uni-lj.si/pluginfile.php/100935/mod_resource/content/52/10.Klasifikacije_in_VMR_s_strojnimi_ucenjem_1920_new.pdf). [Poskus dostopa januar 2023].
- [6] Data Science Blog, "Linear, Quadratic, and Regularized Discriminant Analysis," 2018 [Elektronski]. Dostopen: <https://www.datascienceblog.net/post/machine-learning/linear-discriminant-analysis/>. [Poskus dostopa januar 2023].
- [7] PhysioNet, "EEG Motor Movement/Imagery Dataset," 2009 [Elektronski]. Dostopen: <https://www.physionet.org/content/eegmdb/1.0.0/>. [Poskus dostopa januar 2023].